Statistika - projektni zadatak

Denis Beletić

28. ožujka 2026.

Sadržaj

1 Uvod **2**

2 Objašnjavanje dataset-a **3**

3 Opisna statistika **4**
3.1 Tablica frekvencije izvora električne energije 4
3.2 Srednje vrijednosti 5
3.3 Medijan 6
3.4 Kvartili i interkvartilni raspon 7
3.5 Histogram 8
3.6 Boxplot 9

4 Napredne metode **11**
4.1 Linearna regresija - korelacija 11
4.2 Linearna regresija - regresijski pravac 13

1 Uvod

Statistička analiza globalne proizvodnje električne energije daje nam uvid u ključne energetske trendove koje možemo iskoristiti u razne svrhe, kao npr. radi boljeg planiranja izgradnje energetske infrastrukture i optimizacije proizvodnje.

Analizom možemo također prepoznati zemlje s brzim rastom ili padom proizvodnje, prepoznati najefikasnije distribucijske infrastrukture (prema gubicima u distribuciji i prijenosu električne energije) te pratiti prelazak na obnovljive izvore energije kroz vrijeme (i slično).

Unutar projekta koristiti ću programski jezik Python uz pomoć par paketa (pandas, matplotlib, seaborn, NumPy i Scikit-learn) radi analiziranja, obrade i vizualizacije podataka.

Na GitHub-u se nalazi repozitorij unutar kojeg možete preuzeti sve datoteke vezane za ovaj projektni zadatak: https://github.com/denisbeletic/STAT-ProjektniZadatak

2 Objašnjavanje dataset-a

Dataset nad kojim ćemo vršiti statističku analizu dostupan je na Kaggle-u:
https://www.kaggle.com/datasets/sazidthe1/global-electricity-production/data

Dataset je strukturiran u obliku `.csv` datoteke (`Comma-separated values`) i obuhvaća podatke iz 48 država unutar vremenskog razdoblja od 2010. do 2023. godine. Bitno je napomenuti da navedeni dataset ima preko 120000 zapisa, što znači da ćemo za većinu izračuna, čak i za one jednostavne, morati napisati programski kod u Pythonu da bi mogli analizirati i obraditi podatke budući da bi ručna obrada bila jako zahtjevna vremenski.

Moram napomenuti da neću u ovome dokumentu moći priložiti programske kodove s kojima sam vršio analizu i obradu radi poprilično dugih naredbi u određenim datotekama, a formatiranje izgleda za uredan prikaz preko LaTeX-a na papiru veličine A4 je jednostavno nemoguće.

Ako Vas zanima programski kod za bilo koji primjer, možete ga pronaći na gore navedenoj poveznici na GitHub-u.

U nastavku se nalazi popis stupaca s pripadnim opisima:

Stupac	Opis
country_name	Naziv države
date	Datum mjerenja
parameter	Parametar koji se mjeri unutar retka
product	Izvor električne energije
value	Vrijednost električne energije
unit	Jedinica u kojoj je izražena vrijednost

Primjeri:

country_name: Australia
date: 12/1/2023
parameter: Net Electricity Production
product: Total Combustible Fuels
value: 13397,9356
unit: GWh

country_name: Portugal
date: 1/1/2019
parameter: Distribution Losses
product: Electricity
value: 466,8664
unit: GWh

3 Opisna statistika

U ovome poglavlju prikazati ćemo osnovne statističke metode analize i obrade pomoću kojih ćemo steći bolje razumijevanje podataka s kojima radimo. Prikazati ćemo koliko se određene vrijednosti pojavljuju, srednje vrijednosti, medijane, raspodjelu podataka kroz kvartile i interkvartilni raspon te na kraju vizualno prikazati podatke pomoću histograma i boxplotova.

3.1 Tablica frekvencije izvora električne energije

Svrha tablice frekvencije je prikazati "koliko se često određeni podatak pojavljuje" u skupu podataka. Općenito, koriste se radi boljeg razumijevanja dataseta - omogućuju nam organizirani pregled svih podataka, od onih koji se najčešće pojavljuju do onih koji se najrjeđe pojavljuju, te donošenje daljnjih odluka na temelju tih informacija.

Prikazati ćemo tablicu frekvencije globalnih izvora električne energije 2023 godini:

Ugljen, treset i proizvedeni plinovi	Geotermalni	Nuklearni	Ostali	Prirodni plin
0	185	267	465	527

Nafta i derivati	Vjetar	Hidro	Goriva obnovljivih izvora	Solar
545	550	552	555	564

Kao što možemo vidjeti u tablici, tijekom 2023. godine na temelju preko 4000 mjerenja, u globalnoj se proizvodnji najviše iskoristio izvor solarne energije. Ugljen, treset i proizvedeni plinovi nisu uopće iskorišteni u proizvodnji, a pod "Ostali" smatraju se ostala sagoriva iz neobnovljivih izvora i ostali obnovljivi izvori (nažalost, u dataset-u nije točno objašnjeno koji su to izvori).

Ove smo podatke dobili kroz program `frekvencije.py`. Program vraća svaki izvor i broj zapisa unutar kojih je prikazano da se navedeni izvor iskoristio u proizvodnji električne energije na određenome danu unutar 2023. godine unutar jedne države. Mjerenja za skoro svaku državu su se uvijek izvršavala prvoga dana svakoga mjeseca.

Program sam po sebi ne sortira niti uvrštava podatke u tablicu, već samo broji i vraća relevantne podatke pomoću kojih možemo sami konstruirati tablicu frekvencije, kao što je gore navedena.

3.2 Srednje vrijednosti

Mean, odnosno aritmetička sredina ili srednja vrijednost prikazuje nam prosječnu vrijednost nečega unutar određenome skupu podataka. Njime možemo bolje razumjeti oko kojih se vrijednosti podaci općenito "vrte".

Aritmetička sredina skupa podataka $x_1, x_2, \ldots, x_n$ računa se prema formuli:

$$\bar{x} = \frac{x_1 + x_2 + x_3 + ... + x_n}{n}$$

odnosno:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

gdje je:

- $\bar{x}$ - srednja vrijednost,
- x_i - i-ta vrijednost u skupu podataka,
- n - broj svih promatranih vrijednosti.

U nastavku ćemo prikazati 10 država koje su u 2023. proizvele najviše električne energije iz solarnih izvora, zajedno s njihovom prosječnom proizvodnjom (sve u GWh):

Italy	Korea	Spain	Australia	Brazil
30063,70	31492,62	31492,62	47631,89	48660,35

Germany	Japan	India	United States	China
58463,89	99232,78	119756,05	215256,42	523372,94

$$\bar{x} = \frac{x_{Italy} + x_{Korea} + x_{Spain} + ... + x_{China}}{10} \approx 121693,11$$

Prosječna proizvodnja solarne energije među 10 država s najvećom proizvodnjom iznosila je oko 121693,11 GWh. Ova je količina energije dovoljna za napajanje otprilike 10-30 miljuna kućanstva tijekom cijele godine. Moramo uzeti u obzir da se radi o prosječnoj proizvodnji iz samo jednog, i to obnovljivog, izvora energije.

Gore smo navedene države, njihove proizvodnje i prosječnu proizvodnju svih 10 država dobili kroz program `mean.py`. Program računa za svaku državu ukupnu proizvodnju električne energije kroz 2023. godinu preko solarnih izvora, sortira sve države silazno (što znači da se država s najvećom proizvodnjom nalazi pri vrhu) te ispisuje 10 država s najvišim proizvodnjama. Zatim, program računa i ispisuje aritmetičku sredinu tih 10 država.

3.3 Medijan

Medijan, odnosno srednja vrijednost, je vrijednost u skupu podataka kod koje se 50% podataka nalazi ispod medijana, a 50% iznad. Medijan je vrlo koristan jer jako veliki ili mali brojevi (odnosno 'ekstremni' brojevi) ne utječu na njega, za razliku od mean-a (aritmetičke sredine), kod koje ekstremna vrijednost može poprilično iskriviti rezultat.

Za izračun medijana potrebno je prvo poredati podatke po veličini (silazno ili uzlazno, nije bitno koji poredak), zatim tražimo podatak koji se nalazi na sredini skupa. Ako skup ima **paran** broj podataka, medijan je aritmetička sredina dvaju središnjih podataka.

Ako skup ima **neparan** broj podataka, medijan je vrijednost koja se nalazi točno u sredini skupa.

Pošto smo u prošlom poglavlju prikazali i poredali proizvodnje 10 država, u nastavku ćemo izračunati i njihov medjan.

U skupu imamo 10 država, što znači da će medijan biti aritmetička sredina dvaju središnjih vrijednosti (x_5 i x_6):

$$\tilde{x} = \frac{x_5 + x_6}{2} = \frac{x_{Brazil} + x_{Germany}}{2} = \frac{48660,35 + 58463,89}{2} \approx 53562,12$$

Medijan gore navedenih država iznosi 53562.12 GWh, što je značajno niže od aritmetičke sredine od 121693,11 GWh. To znači da određeni broj država s velikom proizvodnjom povisuje prosjek, dok većina država proizvodi poprilično manje (što je vidljivo iz navedenog skupa).

Do medijana gore navedenih država možemo doći i pomoću programa `medijan.py`, koji funkcionira slično kao i `mean.py`. Program, kao i prethodni, računa ukupnu proizvodnju svake države kroz 2023. preko solarnih izvora i sortira sve države, ali ne računa aritmetičku sredinu već računa medijan (na isti način kao što smo ručno izračunali).

3.4 Kvartili i interkvartilni raspon

Kvartili su vrijednosti koje dijele skup na četiri jednaka dijela. Ispod svakog kvartila se nalazi određeni postotak podataka. Bitno je napomenuti da kao i kod medijana, prije određivanja kvartila potrebno je skup podataka poredati (silazno ili uzlazno).

Postoje 3 glavna kvartila:

- Q_1 **(donji kvartil)** – vrijednost ispod koje se nalazi 25% podataka,
- Q_2 **(medijan)** – vrijednost ispod koje se nalazi 50% podataka,
- Q_3 **(gornji kvartil)** – vrijednost ispod koje se nalazi 75% podataka.

Donji kvartil (Q_1) je medijan donje polovice podataka a gornji kvartil (Q_3) je medijan gornje polovice podataka. Pravila za određivanje kvartila u parnome ili neparnome skupu podataka su ista kao i za medijan.

Interkvartilni raspon IQR je mjera podataka koja prikazuje koliko su rasprđenipodaci koji se nalaze između donjeg i gornjeg kvartila. IQR također nije osjetljiv na ekstremne vrijednosti, a njime možemo vidjeti koliko se podaci unutar srednjih 50% skupa razlikuju.

IQR se definira kao:

$$IQR = Q_3 - Q_1$$

Već kad smo odredili medijan 10 država s najvećom proizvodnjom električne energije iz solarnih izvora, odrediti ćemo i njihove kvartile i IQR.

Za (Q_1) uzimamo medijan donje polovice skupa od 5 podataka, što znači da će medijan biti 3. podatak (x_3), a za (Q_3) uzimamo medijan gornje polovice skupa (također od 5 podataka), što znači da će medijan 8. podatak (x_8):

$$Q_1 = x_3 = x_{Spain} = 43000,50$$
$$Q_3 = x_8 = x_{India} = 119756,05$$

$$IQR = Q_3 - Q_1 = 119756,05 - 43000,50 \approx 76755,55$$

Ovim podacima možemo jasno vidjeti koliko medijan i kvartili daju bolji uvid i "osjećaj" o podacima u odnosu na aritmetičku sredinu. 25% država je 2023. godine proizvelo manje od 43000,5 GWh iz solarnih izvora, što je dovoljno za godišnju opskrbu otprilike 3-5 miljuna kućanstva, dok je 75% država proizvelo manje od 119756,05 GWh, što je dovoljno za godišnju opskrbu otprilike 10-30 miljuna kućanstva.

Gornji kvartil nalazi se vrlo blizu aritmetičke sredine od 121693,11 GWh, što jasno pokazuje koliko nam aritmetička sredina može ponekad dati krivi dojam o podacima.

Do ovih podataka možemo doći također preko programa `kvartili_i_IQR.py`. Program ponovno dohvaća 10 država s najvećim proizvodnjama, ponovno računa medijan (kako bi mogli sve kvartile prikazati), te određuje gornji i donji kvartil (dohvaća 3. i 8. podatak), uspoređuje za svaki slučaj ako je gornji kvartil veći od donjeg, a ako nije, prilagođava redoslijed oduzimanja kako bi IQR bio pozitivan. Na kraju, sve rezultate vraća korisniku.

3.5 Histogram

Histogram je grafički prikaz distribucije podataka koji, za razliku od običnog stupčastog grafa, prikazuje podatke grupirane unutar određenih "granica", odnosno intervala. Stupci prikazuju koliko se često pojavljuju podaci koji se nalaze unutar tog raspona - raspon koji je određen na granicama stupaca, odnosno x-osi. Histogram koristimo kada želimo prikazati distribuciju podataka unutar skupa, umjesto pojedinačnih vrijednosti, kako bi mogli bolje analizirati trendove.

Postoji više načina za određivanje širine raspona histograma, ali mi ćemo u ovome primjeru napraviti 7 jednakih intervala radi jednostavnosti i preglednosti. Koristiti ćemo intervale od 75 tisuća GWh.

U nastavku ćemo prikazati histogram proizvodnje solarne energije istih 10 država:

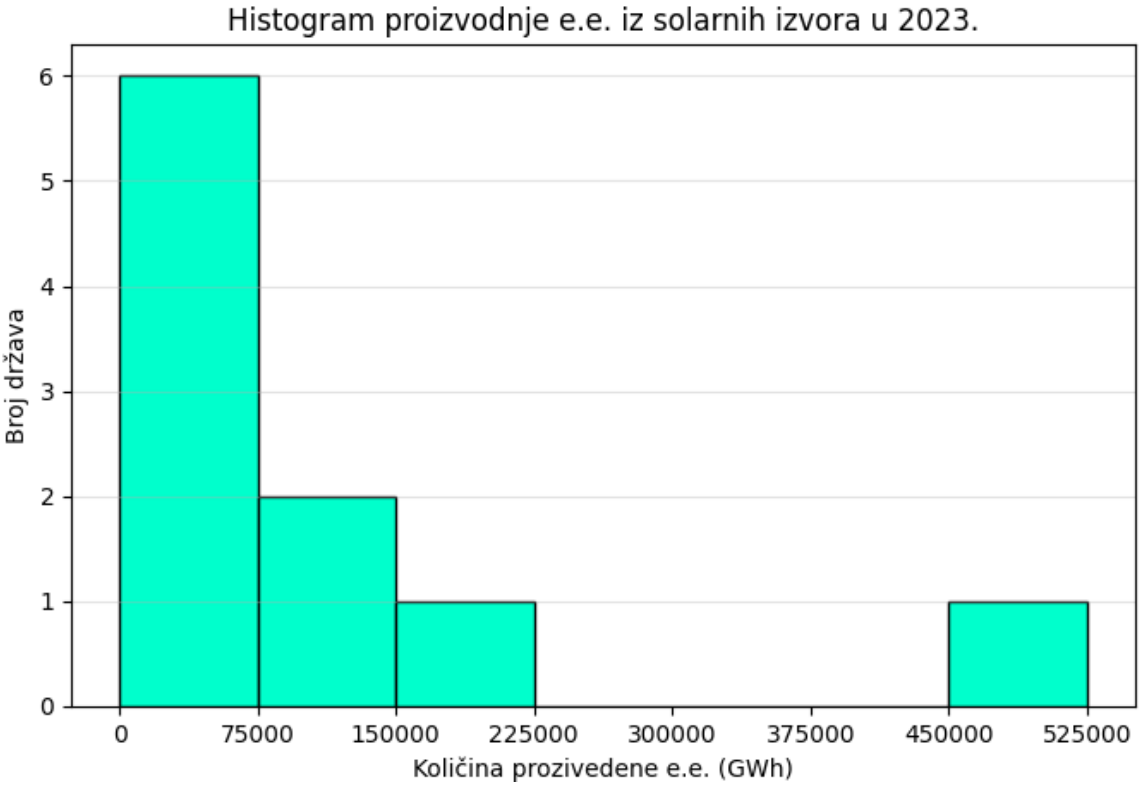

Na temelju prikaza možemo vidjeti da se većina država (90%) nalazi nižim rasponima, dok se samo jedna država (Kina) nalazi na skroz desnome, odnosno najvećem intervalu. Ovakav oblik grafa ima pozitivnu asimetriju, odnosno desno zakošenu distribuciju, što se u energetici često događa jer većinom određeni broj proizvođača nadmaši prosjek proizvodnje ostalih.

Ovaj vizualni prikaz generiran je pomoću programa `histogram.py`. Program ponovno dohvaća 10 država s najvećim proizvodnjama te iscrtava histogram prema podacima. Pri crtanju histograma, program također postavlja intervale od 75 tisuća GWh.

3.6 Boxplot

Boxplot, ili kutijasti graf, je grafički prikaz koji vizualno prikazuje sljedeće mjere: kvartile (Q_1, medijan, odnosno Q_2, Q_3), IQR, minimum i maksimum skupa podataka. Koristimo ga radi brze vizualizacije središnje vrijednosti, raspršenosti podataka i simetrije.

Unutar boxplot-a se nalaze "kutije" s "brkovima". Kutija predstavlja IQR, odnosno srednjih 50% podataka. Unutar kutije se također nalazi jedna horizontalna linija koja predstavlja Q_2, odnosno medijan. Brkovi su linije koje spajaju kutiju s minimalnim i maksimalnim vrijednostima (kraj brka, koji je također označen kao horizontalna linija, pokazuje na maksimum ili minimum skupa).

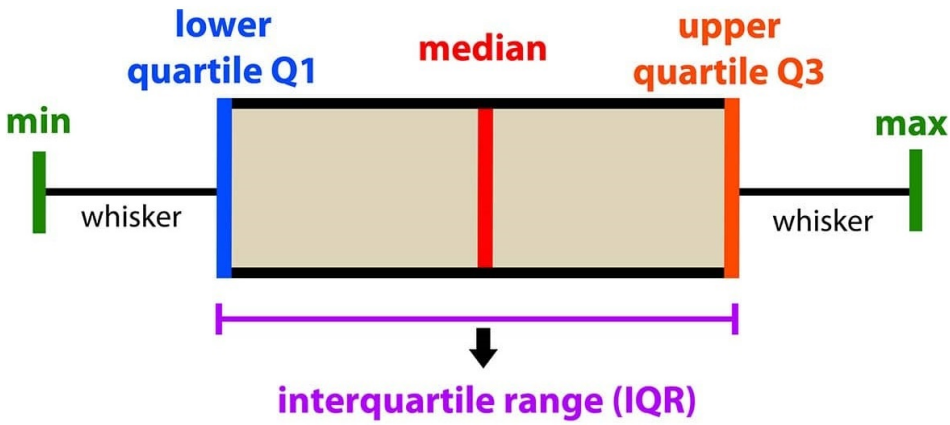

Inače se u boxplot-ovima koriste "outlier-i", odnosno ekstremne vrijednosti. Oni su prisutni kada se brkovi od kutije protežu do najviše:

$$1,5 \cdot IQR,$$

umjesto do minimuma i maksimuma skupa - tada su outlier-i vrijednosti izvan raspona brkova i kutije te su označeni kao točke.

Radi jednostavnosti, nećemo koristiti ekstremne vrijednosti u boxplot-u, već ćemo označiti minimalne i maksimalne vrijednosti brkovima.

Prikazati ćemo boxplot proizvodnje električne energije iz solarnih izvora istih 10 država (Italija, Koreja, Španjolska, Australija, Brazil, Njemačka, Japan, Indija, SAD i Kina) od 2018. - 2023. godine:

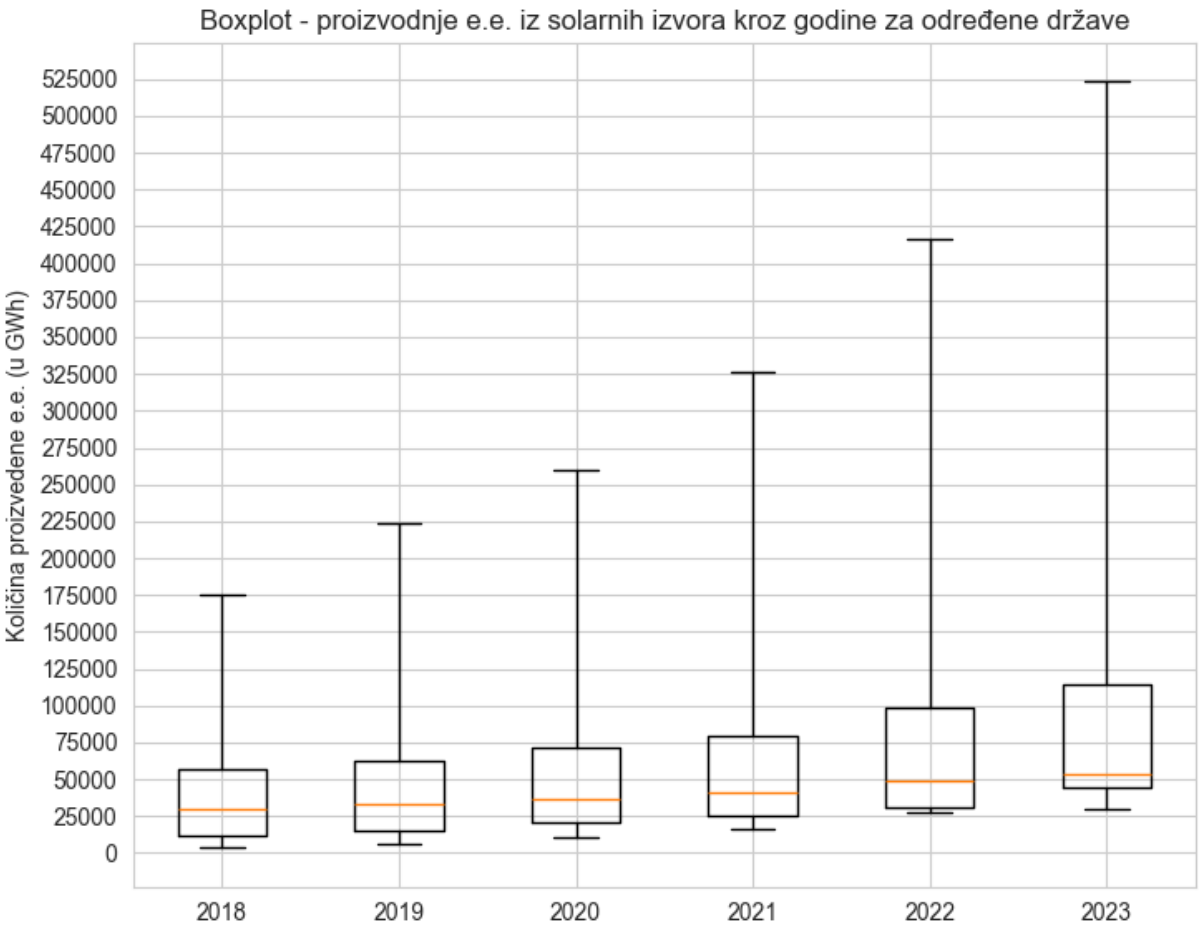

Iz boxplot-a možemo zaključiti da se proizvodnja iz solarnih izvora povećava više-manje linearno iz godine u godinu, s obzirom na rast medijana. Čak i države koje su imale zanemarivu proizvodnju (donji brk) bilježe linearan, stalan rast.

Također možemo uočiti da se u sektoru ovih 10 država povećava varijabilnost (povećava se IQR), to jest kod gornjeg dijela "jačih" proizvođača proizvodnja se povećava brže od donjeg dijela "slabijih" proizvođača.

Naime, najuočljivija promjena kroz godine je poprilično brži, ali i dalje linearan, rast vodećih proizvođača u sektoru (gornji brk). To nam govori da proizvodnja "najjačih" proizvođača znatno brže raste od ostatka.

Ovaj boxplot potvrđuje da se simetričnost, odnosno pozitivna asimetričnost, nije promijenila kroz godine, što smo uočili prvi puta na histogramu. Razlika rasta proizvodnje kod vodećih i kod prosječnih proizvođača se svake godine sve više povećava.

Ovaj vizualni prikaz generiran je pomoću programa `boxplot.py`. Program koristi funkciju koja dohvaća sve proizvodnje električne energije iz solarnih izvora za određenih 10 država unutar jedne godine. Ti se podaci prikupljaju za razdoblje od 2023. do 2018. godine i na kraju program iscrtava boxplot s tim podacima.

4 Napredne metode

U ovome poglavlju prikazati ćemo naprednije metode statističke analize. Izračunati ćemo koeficijent korelacije pomoću Pearsonove formule kako bi se utvrdilo postoji li linearna veza između godine i proizvodnje električne energije iz solarnih izvora, ali ovaj put fokusirati ćemo se na Hrvatsku. Također, prikazati ćemo regresijski pravac kojim možemo dobiti 'osjećaj' o trendu rasta ili pada proizvodnje električne energije.

4.1 Linearna regresija - korelacija

Koeficijent korelacije koristimo kako bi utvrdili koliko je jaka ili slaba linearna veza između uparenih podataka. Koristi se radi boljeg razumijevanja odnosa između podataka.
Vrijednost koeficijenta se nalazi u intervalu $[-1, 1]$, gdje 1 predstavlja savršenu pozitivnu vezu, -1 predstavlja savršenu negativnu vezu a 0 predstavlja nepostojeću linearnu vezu.

Formula "Pearsonovog" koeficijenta korelacije glasi:

$$R = \frac{\sum(x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \cdot \sum(y_i - \bar{y})^2}}$$

gdje su:

- $\bar{x}$, $\bar{y}$ - srednje vrijednosti skupa podataka,
- x_i, y_i - i-te vrijednosti u skupu podataka.

Uzeti ćemo proizvodnje električne energije iz solarnih izvora (u GWh) za Hrvatsku za razdoblje 2018.-2023. (ovo možemo ručno dobiti ili kroz `regresija.py`, objasniti ću poslije čemu sve služi program):

2018.	2019.	2020.	2021.	2022.	2023.
74,9	82,9	95,3	148,5	158,897	604,222

Očito je iz tablice da Hrvatska nema nikakav utjecaj na globalnu proizvodnju električne energije iz solarnih izvora - ukupna količina struje proizvedena u Hrvatskoj u 2023., iako je skoro 4 puta veća količina proizvodnje u odnosu na 2022., je jedva $0,2\%$ ukupne količine električne energije proizvedene u Italiji u 2023. godini - država koja se plasirala na 10. mjesto u svijetu po solarnoj proizvodnji.

U nastavku ćemo prikazati postupak računanja koeficijenta korelacije za Hrvatsku. Prvo ćemo izračunati srednje vrijednosti:

$$\bar{x} = \frac{x_1 + x_2 + ... + x_6}{6} = \frac{2018 + 2019 + 2020 + 2021 + 2022 + 2023}{6} = \mathbf{2020,5}$$

$$\bar{y} = \frac{y_1 + y_2 + ... + y_6}{6} = \frac{74,9 + 82,9 + 95,3 + 148,5 + 158,897 + 604,222}{6} = \mathbf{194,12}$$

Zatim, uvrštavamo podatke u jednadžbu - riješiti ćemo prvo brojnik Pearsonove jednadžbe:

$$\sum (x_i - \bar{x}) \cdot (y_i - \bar{y})$$

$$= (x_1 - \bar{x}) \cdot (y_1 - 0\bar{y}) + (x_2 - \bar{x}) \cdot (y_2 - \bar{y}) + ... + (x_6 - \bar{x}) \cdot (y_6 - \bar{y}) =$$

$$(2018 - 2020,5) \cdot (74,9 - 194,12) + (2019 - 2020,5) \cdot (82,9 - 194,12) + ...$$
$$... + (2023 - 2020,5) \cdot (604,222 - 194,12) = \mathbf{1463,899}$$

Nakon toga, rješavamo nazivnik:

$$\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}$$

$$\sum (x_i - \bar{x})^2 = (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + ... + (x_6 - \bar{x})^2 =$$
$$(2018 - 2020,5)^2 + (2019 - 2020,5)^2 + ... + (2023 - 2020,5)^2 = 17,5$$

$$\sum (y_i - \bar{y})^2 = (y_1 - \bar{y})^2 + (y_2 - \bar{y})^2 + ... + (y_6 - \bar{y})^2 =$$
$$(74,9 - 194,12)^2 + (82,9 - 194,12)^2 + ... + (604,2216 - 194,12)^2 = 207651,8457$$

$$\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2} = \sqrt{17,5 \cdot 207651,8457} = \sqrt{3633907,3} \approx \mathbf{1906,281}$$

Na kraju, uvrštavamo dobivene vrijednosti u originalnu jednadžbu:

$$R = \frac{\sum (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}} = \frac{1463,899}{1906,281} \approx \mathbf{0,768}$$

Iz koeficijenta korelacije možemo ustanoviti da postoji **jaka pozitivna veza** između godine i količine proizvedene el. energije iz solarnih izvora. Koeficijent ne ukazuje na savršenu korelaciju (1) zato jer smo u 2023. bilježili izuzetan "skok" u proizvodnji koji lomi linearnost.

4.2 Linearna regresija - regresijski pravac

Regresijski se pravac koristi radi vizualnog prikazivanja trenda rasta ili pada kroz određeno razdoblje te nam omogućuje predviđanje budućih vrijednosti na temelju postojećih. Funkcionira na principu najmanjih kvadrata - pravac se postavlja tako da je zbroj kvadrata udaljenosti svakog podatka od pravca što manji.

Regresijski pravac opisuje se jednadžbom:

$$\hat{y} = \alpha + \beta \cdot x$$

gdje je:

- α - odsječak $\rightarrow$ određuje poziciju pravca na grafu,
- β - nagib pravca,
- $\hat{y}$ - predviđena vrijednost zavisne varijable,
- x - nezavisna varijabla.

Nagib i odsječak pravca odrađujemo sljedećim formulama:

$$\beta = \frac{\sum(x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum(x_i - \bar{x})^2}, \quad \alpha = \bar{y} - \beta \cdot \bar{x}$$

Izračunati ćemo jednadžbu regresijskog pravca za Hrvatsku na temelju gore navedenih podataka te ćemo ga kasnije vizualizirati programom `regresija.py`.

Pošto smo već izračunali sve vrijednosti, lagano ih možemo uvrstiti u jednadže:

$$\beta = \frac{\sum(x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{1463,899}{17,5} = \mathbf{83,651}$$

$$\alpha = \bar{y} - \beta \cdot \bar{x} = 194,12 - (83,651 \cdot 2020,5) = 194,12 - 169016,8455 \approx \mathbf{-168822,726}$$

Jednadžba linearnog regresijskog pravca za Hrvatsku glasi:

$$\hat{\mathbf{y}} = \mathbf{-168822,726 + 83,651 \cdot x}$$

Vizualizacija gore izračunate jednadžbe pravca:

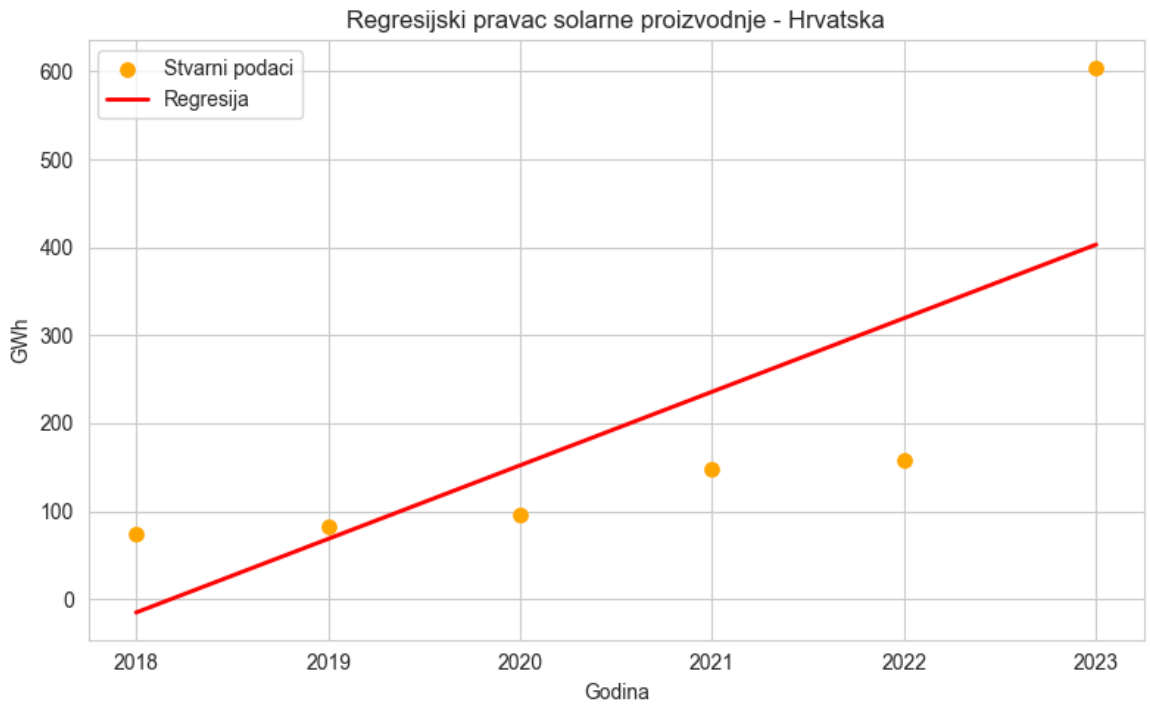

Gore navedena vizualizacija i podaci o solarnoj proizvodnji Republike Hrvatske dobiveni su kroz `regresija.py`. Program koristi skoro pa istu funkciju za dohvaćivanje podataka kao u `boxplot.py` ali se ovaj put koristi samo za Hrvatsku. Program prvo ispisuje podatke o proizvodnjama te ih sprema u određenim varijablama koje se kasnije koriste za vizualizaciju regresijskog pravca.

`Python` modul `Scikit-learn` vrši (unutarnji) izračun - modul se inače koristi u Machine Learning-u (odlučio sam iskoristiti ovu metodu zbog kraćeg programskog koda, pošto je program većinom namijenjen za vizualizaciju - nisam htio bezveze ići implementirati cijeli postupak računa da bi vizualizirao pravac kada sam sve već izračunao "na papiru", nije mi imalo poante samo zbog grafa ponavljati sve to).